

# Rapport de Conception

## Ingestion des Données SAP/Oracle via Kafka vers la Couche Bronze

TMU — Juillet 2026

### 1. Objectif

Ce document décrit la conception du pipeline d'ingestion permettant de capter les transactions issues de SAP (ventes) et Oracle (charges), de les publier sur une file Kafka, puis de les déposer telles quelles dans la couche Bronze du Data Lake, sans transformation ni enrichissement à ce stade.

### 2. Principe général : architecture médaille

Le Data Lake suit l'architecture en couches dite « médaille » (Bronze / Silver / Gold), standard reconnu pour l'ingestion de données hétérogènes. La couche Bronze, objet de ce rapport, a un rôle précis : stocker la donnée brute, exactement comme reçue, sans aucune transformation, afin de garantir qu'aucune perte ou altération ne se produit avant les étapes ultérieures d'enrichissement (couche Silver, hors périmètre de ce rapport).




FIGURE 1 – Pipeline d'ingestion SAP/Oracle vers la couche Bronze via Kafka

### 3. Étape 1 : capture des données sources

La capture des transactions SAP et Oracle s'appuie sur le principe du **Change Data Capture (CDC)** : plutôt que d'interroger périodiquement les bases sources (ce qui surchargerait les systèmes de production), un connecteur dédié observe les nouvelles écritures et les publie immédiatement. Dans le cadre du POC, ce connecteur est simulé par un producteur Python générant des transactions réalistes à intervalles réguliers, reproduisant le comportement d'un connecteur CDC réel (type Debezium) sans en nécessiter l'installation complète.

### 4. Étape 2 : publication sur les files Kafka

#### 4.1 Topics dédiés par source

Deux topics Kafka distincts sont définis, un par système source, afin de préserver l'indépendance des flux et de permettre un traitement différencié si nécessaire :

- `sap.ventes.raw` : contient chaque transaction de vente SAP, sérialisée en JSON.
- `oracle.charges.raw` : contient chaque charge/achat Oracle, sérialisée en JSON.

#### 4.2 Structure du message

Chaque message publié contient, au minimum : un identifiant unique de transaction, l'horodatage d'origine côté système source, le système émetteur (**SAP** ou **ORACLE**), et la charge utile brute (montant, références client/contrat, etc.) sans aucune résolution ni validation à ce stade.

#### 4.3 Garanties Kafka retenues

- **Partitionnement** par clé client ou contrat, pour garantir l'ordre de traitement des transactions d'un même client.
- **Rétention** configurée pour conserver les messages suffisamment longtemps afin de permettre un

rejeu en cas d'incident du consommateur Bronze.

- **Acquittement** (`acks=all`) côté producteur pour garantir qu'aucune transaction n'est perdue avant confirmation d'écriture.

## 5. Étape 3 : ingestion dans la couche Bronze

Un service consommateur dédié (« Bronze Loader ») s'abonne aux deux topics et écrit chaque message reçu dans le Data Lake, sans transformation, selon les principes suivants :

1. **Fidélité absolue** : le message est stocké tel que reçu (même structure JSON), aucune validation métier n'est appliquée à ce stade.
2. **Partitionnement physique** : les fichiers sont organisés par source et par date (`bronze/sap_ventes/annee=202`) facilitant les relectures ciblées.
3. **Format de stockage** : Parquet, choisi pour sa compression efficace et sa compatibilité native avec les moteurs d'analyse (Spark, ClickHouse, DuckDB).
4. **Métadonnées de traçabilité** : chaque fichier Bronze conserve l'offset Kafka d'origine, permettant de savoir exactement quels messages ont été intégrés et de relancer l'ingestion en cas d'écart.

## 6. Ce que la couche Bronze ne fait pas

Il est essentiel de clarifier les limites de cette couche pour éviter toute confusion lors de la présentation : la couche Bronze ne résout aucune référence (pas d'appel au référentiel `mdm`), ne calcule aucun code analytique, et ne rejette aucune transaction même invalide. Ces traitements interviennent uniquement lors du passage vers la couche Silver, étape suivante non couverte par ce rapport.